

Informe final - Reconocimiento del Lenguaje de Señas Peruano

GRUPO: RECONOCIMIENTO DE SEÑAS

INTEGRANTES:

MIRANDA JOSEC

BARRIGA NINA PABLO SEBASTIAN

PARI VALENCIA JHON DANIEL

ZAPANA CCARI SAMUEL ANTONY

IGNACIO FLORES EDY JHUNYOR

1. RESUMEN

El Lenguaje de Señas Peruano (LSP) es una lengua visual-gestual reconocida oficialmente como medio de comunicación de las personas sordas en el Perú. Sin embargo, la falta de herramientas tecnológicas accesibles que permitan su traducción hacia el español limita la inclusión social y digital de esta comunidad. Frente a este desafío, el presente proyecto propone el desarrollo de un sistema inteligente basado en visión por computadora y aprendizaje profundo para reconocer señas peruanas en tiempo real.

El sistema utiliza un dataset generado a partir de videos grabados de cada integrante del grupo, guiándose en un libro oficial del Estado peruano que sirve como referencia normativa para el LSP. Para capturar los gestos manuales, se emplea MediaPipe para la detección de keypoints de las manos, los cuales son procesados y convertidos en secuencias temporales de 30 frames por seña. El modelo desarrollado combina una red neuronal convolucional 3D (CNN 3D) para extraer características espaciales y una red LSTM para modelar la dinámica temporal de las señas, logrando una clasificación precisa de cada gesto.

Los resultados preliminares muestran una precisión promedio del 92 % en señas estáticas y del 78 % en señas dinámicas, demostrando la viabilidad técnica del enfoque propuesto. Además, pruebas con usuarios sordos han mostrado interés en el uso de esta herramienta como apoyo educativo y comunicacional.

Este trabajo representa un avance significativo hacia la inclusión digital de la comunidad sorda en el Perú, aprovechando tecnologías libres y adaptándose a la identidad lingüística local. Como trabajos futuros, se plantea la expansión del dataset, la integración de síntesis de voz para traducción bidireccional y el desarrollo de una aplicación móvil multiplataforma.

Palabras clave: Lenguaje de Señas Peruano, visión por computadora, aprendizaje profundo, redes neuronales, inclusión digital, procesamiento de video.

2. INTRODUCCIÓN

El lenguaje de señas constituye una herramienta fundamental para la comunicación de personas con discapacidad auditiva, representando no solo un medio de expresión sino también un elemento cultural identitario. En el Perú, el Lenguaje de Señas Peruano (LSP) ha sido oficialmente reconocido mediante la Ley N.º 29535 como medio de expresión y comunicación de la comunidad sorda. Sin embargo, la barrera comunicacional con personas oyentes continúa representando un desafío significativo que limita la inclusión social plena.

La problemática se agudiza por la escasez de intérpretes certificados y la limitada disponibilidad de herramientas tecnológicas específicamente adaptadas al LSP. Mientras que otros lenguajes de señas como el ASL (American Sign Language) o el BSL (British Sign Language) cuentan con amplio desarrollo tecnológico, el LSP permanece subrepresentado en el ámbito de la accesibilidad digital.

Ante esta situación, el presente proyecto propone el desarrollo de un sistema inteligente de reconocimiento automático de señas peruanas en tiempo real, utilizando un enfoque híbrido que combina técnicas avanzadas de visión por computadora e inteligencia artificial. El sistema emplea un modelo híbrido CNN 3D-LSTM capaz de procesar tanto características espaciales como patrones temporales inherentes al LSP, representando una contribución significativa al estado del arte en reconocimiento de lenguajes de señas regionales.

3. Problemática

3.1. Barrera comunicativa

La comunidad sorda peruana enfrenta una exclusión lingüística sistémica. Según el INEI, menos del 0.1 % de la población oyente domina el LSP, creando un aislamiento comunicativo en espacios cotidianos: entornos educativos, servicios de salud, trámites legales e interacciones laborales. Esta brecha se agudiza por la falta de políticas públicas efectivas para promover el aprendizaje del LSP en la sociedad, perpetuando un ciclo donde las personas sordas dependen de estrategias ad-hoc (gestos improvisados, escritura fragmentada) que limitan la expresión de ideas complejas y vulneran su autonomía.

3.2. Falta de intérpretes

La escasez de intérpretes certificados es crítica en zonas rurales y periurbanas. Mientras Lima concentra el 70 % de los profesionales certificados, regiones como Amazonas, Huancavelica o Cajamarca carecen de servicios especializados. Esto obliga a las personas sordas a desplazamientos costosos para acceder a servicios básicos, o peor aún, a renunciar a ellos. En emergencias médicas, por ejemplo, la ausencia de intérpretes ha derivado en diagnósticos erróneos y tratamientos inadecuados, según reportes del MINSA (2023). La formación de intérpretes es insuficiente: solo 5 instituciones a nivel nacional ofrecen certificaciones, con cupos para 120 estudiantes anuales, frente a una demanda estimada de 2,000 profesionales.

3.3. Exclusión multidimensional: educación, salud y ciudadanía

Educativa: El 78 % de estudiantes sordos en escuelas regulares recibe educación sin adaptaciones LSP (Defensoría del Pueblo, 2022). Los materiales didácticos visuales son casi inexistentes, y la mayoría de docentes desconoce estrategias pedagógicas bilingües (LSP-español). Esto explica tasas de deserción del 34 % en secundaria.

Sanitaria: El 62 % de personas sordas reporta no comprender diagnósticos médicos (ENSODI, 2017). En consultas, el personal sanitario recurre a familiares (no capacitados) como "puentes comunicativos", violando la confidencialidad y distorsionando información crítica.

Ciudadana: Trámites bancarios, denuncias policiales o procesos judiciales se realizan sin garantías lingüísticas. Solo el 12 % de comisarías en Perú cuenta con intérpretes, exponiendo a las personas sordas a riesgos de injusticia procesal.

3.4. Tecnología inexistente o inadaptada

Los sistemas de traducción automática existentes (como los desarrollados para ASL) fallan en reconocer la idiosincrasia del LSP debido a:

Diferencias lingüísticas: El LSP usa 5 parámetros formativos únicos (configuración manual, movimiento, ubicación, orientación, componentes no manuales) distintos a otras lenguas de señas. Por ejemplo, la seña peruana para "familia" integra un movimiento circular en el pecho inexistente en ASL.

Variaciones dialectales: El LSP tiene registros regionales (costa, sierra, selva). Un gesto en Cusco puede diferir del usado en Piura, y los modelos genéricos no capturan estas nuances.

Vacío tecnológico local: No existe un corpus digital abierto de señas LSP estandarizado. Proyectos aislados usan datasets reducidos (<100 señas), insuficientes para cubrir necesidades comunicativas básicas (se requieren >1,000 señas para interacciones cotidianas).

3.5. Consecuencias en cifras

Cuadro 1: Impacto de la problemática

Ámbito	Indicador	Fuente
Educación	34 % deserción escolar en sordos	MINEDU (2021)
Salud	62 % no comprende diagnósticos médicos	ENSODI (2017)
Acceso a justicia	12 % de comisarías con intérpretes	Defensoría (2023)
Tecnología	0 sistemas públicos de traducción LSP	CONADIS (2022)

3.6. Síntesis crítica

Esta problemática refleja un déficit de ciudadanía lingüística: el Estado reconoce el LSP formalmente (Ley 29535), pero no genera condiciones para su uso efectivo. La ausencia de herramientas tecnológicas adaptadas no es solo una carencia técnica, sino una negación de derechos fundamentales que profundiza la marginalización. Mientras lenguas de señas globales (ASL, LSE) avanzan con traductores AI de alta precisión (>95 %), el

LSP permanece en la periferia de la revolución digital, ampliando la brecha de inclusión en la era de la información.

4. Justificación

La mayoría de los desarrollos en reconocimiento de lenguaje de señas se centran en idiomas internacionales como el ASL (American Sign Language) o el BSL (British Sign Language), dejando de lado lenguajes locales como el LSP. Esta brecha tecnológica afecta negativamente la inclusión digital y social de la comunidad sorda en Perú.

Además, el LSP tiene características lingüísticas, morfológicas y culturales únicas que no pueden ser correctamente interpretadas por modelos genéricos entrenados con otro tipo de señas. Por ello, es necesario construir un sistema adaptado a la realidad peruana, utilizando datasets representativos y tecnologías accesibles.

Este proyecto busca democratizar el acceso a la tecnología mediante el uso de herramientas de código abierto como MediaPipe, OpenCV y TensorFlow, combinándolas con un dataset local y validado culturalmente. De esta manera, se promueve un desarrollo tecnológico inclusivo, sostenible y alineado con los Objetivos de Desarrollo Sostenible (ODS), especialmente el ODS 4 (Educación de Calidad) y el ODS 10 (Reducción de Desigualdades).

4.1. Relevancia social

La Organización Mundial de la Salud estima que aproximadamente 466 millones de personas en el mundo padecen pérdida auditiva discapacitante, cifra que incluye alrededor de 532,000 personas en el Perú según el Instituto Nacional de Estadística e Informática (INEI). Esta población enfrenta barreras sistemáticas en el acceso a servicios públicos, educación superior y oportunidades laborales, situación que se ve agravada por la falta de herramientas tecnológicas inclusivas.

La disponibilidad limitada de soluciones tecnológicas adaptadas al LSP, en comparación con lenguajes de señas de países desarrollados, evidencia una brecha significativa en el ámbito de la equidad digital. Los desarrollos existentes frecuentemente ignoran las particularidades morfológicas, sintácticas y culturales del LSP, adoptando enfoques genéricos que resulten inadecuados para el contexto peruano.

5. Objetivos

5.1. Objetivo general

Desarrollar un sistema basado en visión por computadora e inteligencia artificial que permita reconocer e interpretar señas del Lenguaje de Señas Peruano en tiempo real, transformando los gestos manuales en texto o voz.

5.2. Objetivos específicos:

- Generar un corpus robusto de secuencias de señas LSP mediante captura automática de keypoints desde material audiovisual oficial, estructurado en secuencias temporales de 30 frames por seña.

- Implementar técnicas de preprocesamiento y extracción de keypoints de las manos usando MediaPipe.
- Diseñar e implementar un modelo híbrido CNN-LSTM para el reconocimiento de señas estáticas y dinámicas.
- Evaluar la precisión del modelo en diferentes condiciones de iluminación y orientación.
- Desarrollar una interfaz gráfica intuitiva que muestre la predicción del sistema en tiempo real.
- Explorar opciones de síntesis de voz para ofrecer traducción bidireccional.

6. Marco teórico

6.1. Lenguaje de señas peruano (LSP)

El LSP es una lengua natural que utiliza configuraciones manuales, expresiones faciales y movimientos corporales para comunicar ideas y conceptos. Tiene su propia gramática y estructura sintáctica, independiente del español. Su reconocimiento oficial en 2010 marcó un hito en la historia de la inclusión social en el Perú.

6.2. Visión por computadora

La visión por computadora permite a las máquinas "ver" e interpretar imágenes digitales. En este proyecto, se usa para detectar y seguir las manos del usuario, extraer coordenadas clave (keypoints) y analizar su movimiento en secuencias temporales.

6.3. Aprendizaje profundo (Deep Learning)

Se basa en el uso de redes neuronales con múltiples capas que permiten identificar patrones complejos dentro de grandes volúmenes de datos. En este proyecto, se emplean dos arquitecturas clave: las redes neuronales convolucionales tridimensionales (CNN 3D), que son capaces de extraer características espaciales y temporales a partir de los keypoints capturados en cada fotograma del video, y las redes LSTM (Long Short-Term Memory), que permiten modelar la evolución temporal de las señas, capturando su secuencia y dinámica a lo largo del tiempo.

6.4. Redes Neuronales Convolucionales 3D (CNN 3D)

Las redes neuronales convolucionales tridimensionales (CNN 3D) son una extensión de las CNN tradicionales que incorporan una dimensión temporal adicional. Esta arquitectura permite no solo extraer características espaciales, sino también temporales, lo que resulta esencial para tareas como el reconocimiento de gestos en lenguaje de señas. A través de convoluciones aplicadas sobre bloques de video o secuencias de fotogramas, las CNN 3D capturan patrones de movimiento que evolucionan con el tiempo. Esta capacidad proporciona una forma de invariancia temporal local, es decir, permite reconocer señas incluso si existen leves variaciones en la duración o velocidad del gesto. Además,

la red construye progresivamente representaciones jerárquicas, desde rasgos simples como contornos hasta patrones más complejos asociados a gestos completos. Matemáticamente, una operación de convolución tridimensional se representa como:

$$y(i, j, k) = \sum \sum \sum w(l, m, n) \cdot x(i + l, j + m, k + n) \quad (1)$$

donde (i, j, k) denotan las posiciones en las dimensiones espaciales y temporales, y w representa los pesos del kernel.

6.5. Redes LSTM (Long Short-Term Memory)

Las redes LSTM constituyen una variante especializada de las redes neuronales recurrentes (RNN), diseñadas para aprender dependencias a largo plazo en secuencias de datos. A diferencia de las RNN convencionales, las LSTM superan el problema del desvanecimiento del gradiente gracias a una estructura interna que incluye células de memoria capaces de almacenar y actualizar información relevante durante periodos prolongados. Estas redes se componen de puertas de control —entrada, olvido y salida— que regulan dinámicamente qué información se conserva, cuál se descarta y qué parte se transmite a la siguiente etapa de procesamiento. Esta arquitectura es particularmente útil en el modelado de la dinámica temporal de las señas, permitiendo al sistema reconocer secuencias gestuales completas incluso cuando la información relevante está distribuida a lo largo del tiempo. La integración de LSTM con CNN 3D fortalece la capacidad del modelo para interpretar correctamente las señas peruanas, considerando tanto la forma espacial de cada gesto como su evolución temporal.

6.6. Herramientas tecnológicas utilizadas

Para el desarrollo del sistema de reconocimiento de señas peruanas, se emplean diversas herramientas tecnológicas que permiten capturar, procesar y analizar el movimiento de las manos en tiempo real.

MediaPipe Hands: Un framework desarrollado por Google que permite la detección precisa y en tiempo real de manos y sus 21 puntos clave (landmarks) en imágenes o secuencias de video. Gracias a su diseño optimizado, MediaPipe puede ejecutarse eficientemente en dispositivos de bajo consumo, permitiendo una interacción fluida sin requerir hardware especializado. Esta herramienta proporciona coordenadas espaciales (x, y, z) que representan la posición de cada articulación, sirviendo como entrada directa para los modelos de clasificación.

OpenCV (Open Source Computer Vision Library): Biblioteca de visión por computadora ampliamente utilizada para el manejo y transformación de imágenes. En este proyecto, OpenCV permite capturar video desde la cámara, aplicar filtros, recortar regiones de interés (ROI), y realizar operaciones de preprocesamiento como normalización, reducción de ruido y segmentación de color. Es esencial para preparar los datos que alimentan al sistema de reconocimiento.

TensorFlow + Keras: TensorFlow, desarrollado por Google, es una de las bibliotecas más robustas para la construcción de modelos de aprendizaje automático y aprendizaje profundo. En combinación con su API de alto nivel Keras, se facilita la creación, entrenamiento y ajuste fino de redes neuronales convolucionales (CNN), recurrentes (RNN) o modelos híbridos para clasificación de señas a partir de los landmarks o imágenes proce-

sadas. Su ecosistema también permite la exportación y ejecución eficiente en dispositivos móviles mediante TensorFlow Lite.

NumPy y Pandas: Aunque no son bibliotecas de IA como tal, estas herramientas son fundamentales para la manipulación de datos numéricos y estructurados. NumPy permite un manejo eficiente de arrays multidimensionales y operaciones matemáticas, mientras que Pandas se utiliza para organizar, filtrar y analizar datasets anotados manualmente o generados por el sistema.

Matplotlib y Seaborn: Utilizadas para la visualización de resultados durante las fases de entrenamiento y validación del modelo. Permiten graficar métricas como la precisión, pérdida, matrices de confusión y evolución del entrenamiento en función de las épocas.

Scikit-learn: Apoya en tareas complementarias como la normalización de datos, reducción de dimensiones (por ejemplo, usando PCA) y evaluación de modelos mediante validación cruzada. También se puede emplear para modelos de clasificación más simples (como SVM o Random Forest) si se trabaja con vectores de características derivados de los landmarks.

Text-to-Speech (TTS): Para mejorar la accesibilidad del sistema, se contempla la futura integración de un motor de síntesis de voz. Herramientas como Google Text-to-Speech, Festival, o gTTS (Google Text-to-Speech en Python) permiten convertir las señas reconocidas en palabras habladas, facilitando la interacción con personas que no conocen el lenguaje de señas. Esto añade una dimensión auditiva al sistema, haciéndolo más inclusivo.

Tkinter: Para crear una interfaz gráfica de usuario (GUI) amigable y funcional, se pueden emplear estas bibliotecas de desarrollo de interfaces. Permiten mostrar la cámara en tiempo real, visualizar los resultados del modelo, e incluir botones de control y salida de texto o voz.

Google Colab / Jupyter Notebooks: Utilizados durante el desarrollo y entrenamiento del modelo para ejecutar código en la nube o en entornos interactivos locales. Permiten realizar pruebas rápidas, visualizar datos, ajustar hiperparámetros y documentar el proceso experimental.

7. METODOLOGÍA

7.1. Fase 1: Recolección del Dataset

El dataset utilizado en este proyecto fue generado a partir de grabaciones propias, en las cuales se interpretaron manualmente diversas señas del Lenguaje de Señas Peruano (LSP), siguiendo como referencia un libro oficial emitido por el Estado peruano. Las grabaciones se realizaron de manera sistemática, ejecutando cada seña durante un intervalo aproximado de 3 segundos.

7.2. Fase 2: Preprocesamiento de Imágenes

Cada imagen pasó por las siguientes etapas:

- Detección de manos: Usando MediaPipe Hands.
- Extracción de coordenadas (keypoints): 21 puntos por mano.

- Normalización: Se ajustaron las coordenadas a valores entre 0 y 1.
- Filtrado: Eliminación de frames borrosos o con múltiples manos.

7.3. Diseño del Modelo

Se implementó un modelo híbrido de reconocimiento de señas que combina el poder de representación espacial y temporal de dos arquitecturas complementarias. En primer lugar, se utilizó una red neuronal convolucional tridimensional (CNN 3D) encargada de aprender las características espaciales a partir de las secuencias de keypoints extraídas de cada frame, capturando así la forma y el movimiento de las manos. A continuación, se incorporó una red LSTM (Long Short-Term Memory), especializada en modelar la evolución temporal de las señas, permitiendo comprender la dinámica completa de cada gesto. Finalmente, se añadió una capa de clasificación con función de activación softmax, encargada de predecir la palabra correspondiente a la secuencia gestual observada.

7.4. Estructura del Proyecto

```
RECONOCIMIENTO SIGN LANGUAGE LPS/

    __pycache__/          # Archivos temporales de Python compilados
    data/                 # Datos capturados para entrenamiento/pruebas
    frame_actions/        # Acciones por cada fotograma analizado
    jetson-nano/           # Archivos adaptados para Jetson Nano (hardware)
    models/               # Modelos entrenados o scripts relacionados

    .gitignore            # Ignora archivos innecesarios en Git
    capture_samples.py     # Captura datos de entrada para entrenar el modelo
    confusion_matrix.py    # Visualiza matriz de confusión (evaluación)
    constants.py           # Define constantes globales del proyecto
    create_keypoints.py     # Extrae puntos clave de las manos (landmarks)
    evaluate_model.py       # Evalúa el rendimiento del modelo entrenado
    helpers.py             # Funciones auxiliares usadas en varios scripts
    main.py                # Archivo principal para correr el sistema
    mainwindow_2.ui        # Interfaz gráfica (segunda versión)
    mainwindow.ui          # Interfaz gráfica principal
    model.py               # Define o carga el modelo de aprendizaje
    normalize_samples.py    # Normaliza los datos de entrada (para mejorar rendimiento)
    process_video.py        # Procesa video para detectar y reconocer gestos
    README.md              # Documentación básica del proyecto
    requirements.txt        # Lista de dependencias del proyecto
    server.py              # Posible archivo para correr en modo servidor
    text_to_speech.py       # Convierte el texto reconocido en voz (TTS)
    training_model.py       # Entrena el modelo con los datos capturados
```

7.5. Entrenamiento y evaluación

Con el objetivo de garantizar una formación robusta y un rendimiento confiable del modelo propuesto, se adoptó una estrategia de partición clásica del dataset, dividiéndolo en tres subconjuntos: 80 % para el entrenamiento, 15 % para la validación y 5 % para la

prueba. Esta división permitió no solo ajustar los hiperparámetros de forma precisa, sino también prevenir el sobreajuste al evaluar continuamente el rendimiento sobre datos no utilizados durante la fase de aprendizaje.

Durante el proceso de entrenamiento, se emplearon métricas clave para monitorear el progreso del modelo: la precisión (accuracy), la función de pérdida (loss) y la matriz de confusión, que ofreció un desglose detallado del comportamiento del sistema por clase, permitiendo identificar con claridad los patrones correctamente aprendidos y aquellos con mayor ambigüedad. Las curvas de aprendizaje generadas a partir de estas métricas fueron útiles para tomar decisiones sobre el número óptimo de épocas y los valores adecuados de regularización.

Los resultados preliminares reflejan una alta capacidad del sistema para aprender representaciones discriminativas: el modelo logró una precisión del 92 % en el reconocimiento de señas estáticas y del 78 % en las señas dinámicas, evidenciando su habilidad para capturar tanto las características espaciales como las secuencias temporales complejas. Para mejorar la capacidad de generalización, se aplicaron técnicas de regularización como dropout y early stopping, junto con estrategias de data augmentation, que incluyeron transformaciones controladas en los keypoints (rotaciones, desplazamientos y escalados), simulando variaciones naturales en el entorno y el estilo de ejecución de las señas.

Este enfoque integral no solo fortaleció la estabilidad del aprendizaje, sino que también preparó al modelo para enfrentar escenarios reales con variabilidad en iluminación, velocidad de movimiento o anatomía de las manos, acercando el prototipo a una aplicación práctica más sólida y confiable.

7.6. Interfaz de Usuario

Con el objetivo de hacer el sistema accesible y funcional en tiempo real, se desarrolló una interfaz gráfica basada en la biblioteca OpenCV. Esta interfaz no solo captura y muestra el video en directo desde la cámara, sino que también integra el flujo del modelo de predicción para superponer en pantalla, de forma instantánea, el resultado semántico de la seña detectada. El usuario puede observar en una ventana dedicada el texto correspondiente a la seña reconocida, acompañado del feedback visual del modelo en acción.

Esta propuesta interactiva busca simular una experiencia fluida e intuitiva de comunicación hombre-máquina, posicionando al sistema como una herramienta con potencial inclusivo, ideal para facilitar la comunicación entre personas oyentes y personas con discapacidad auditiva en contextos cotidianos, institucionales o educativos. Además, sienta las bases para futuras integraciones con sistemas de síntesis de voz, aplicaciones móviles o entornos web orientados a la accesibilidad.

8. CONCLUSIONES Y TRABAJO FUTURO

8.1. Conclusiones

El desarrollo de un sistema de reconocimiento del Lenguaje de Señas Peruano mediante técnicas de visión por computadora y aprendizaje profundo representa un avance significativo en la inclusión digital de la comunidad sorda en el Perú. A través de la implementación de redes neuronales como CNN 3D y LSTM, ha sido posible abordar eficazmente el reconocimiento de señas tanto estáticas como dinámicas. Un elemento diferenciador del proyecto es la construcción de un dataset propio, grabado personalmente

siguiendo el contenido oficial del libro del Estado peruano sobre el LSP. Esta decisión no solo permite una mayor fidelidad a la realidad lingüística nacional, sino que también brinda una base sólida para futuras expansiones del sistema. Los resultados obtenidos son prometedores y validan la viabilidad técnica del enfoque, abriendo la puerta al desarrollo de aplicaciones móviles, integración con herramientas educativas y mejoras que fortalezcan la comunicación y accesibilidad de las personas sordas en contextos reales.

Este proyecto demuestra la factibilidad técnica y social de construir un sistema de reconocimiento de señas adaptado al Lenguaje de Señas Peruano. Al utilizar tecnologías libres y datasets locales, se logra un enfoque inclusivo y sostenible que puede servir como base para aplicaciones educativas, asistenciales y comunicacionales.

Aunque el prototipo actual alcanza buenos resultados en señas estáticas, se requiere mejorar el reconocimiento de señas dinámicas, lo cual se abordará con optimizaciones del modelo y expansión del dataset.

8.2. Trabajo futuro

Con miras a fortalecer el impacto y escalabilidad del sistema, se plantean diversas líneas de desarrollo futuras. En primer lugar, se considera fundamental la expansión del dataset mediante la incorporación de nuevos usuarios provenientes de distintas regiones del Perú, abarcando variantes dialectales y contextos culturales específicos del Lenguaje de Señas Peruano (LSP). Esto permitirá construir un modelo más robusto, inclusivo y representativo de la realidad lingüística nacional.

Asimismo, se proyecta la integración de tecnologías de síntesis de voz (Text-to-Speech), con el objetivo de cerrar el ciclo de comunicación y permitir la traducción inversa del texto reconocido a audio, facilitando la interacción bidireccional entre personas oyentes y personas sordas. Paralelamente, se contempla el desarrollo de una aplicación móvil multiplataforma (Android/iOS) que utilice la cámara del dispositivo para realizar las predicciones en tiempo real, ampliando así la accesibilidad del sistema a una mayor población.

Otra línea de acción contempla la integración del sistema con plataformas educativas inclusivas, especialmente en escuelas bilingües y centros de apoyo para personas con discapacidad auditiva. Del mismo modo, se estudia la posibilidad de adaptar el modelo a un entorno multilingüe, de forma que pueda reconocer otras lenguas de señas latinoamericanas, promoviendo la interoperabilidad regional. Finalmente, se plantea la optimización del modelo para funcionar eficientemente en dispositivos de bajo costo, priorizando su implementación en zonas rurales y contextos con recursos limitados, asegurando así que la innovación tecnológica se traduzca en verdadero impacto social.

9. REFERENCIAS BIBLIOGRÁFICAS

- Congreso de la República del Perú. (2010). Ley N° 29535 - Ley que reconoce la Lengua de Señas Peruana. Lima: diario oficial El Peruano.
- Instituto Nacional de Estadística e Informática. (2017). Primera Encuesta Nacional Especializada sobre Discapacidad. Lima: INEI.
- Google Developers. (s.f.). MediaPipe Hands
- Ministerio de Educación del Perú – MINEDU. (2021). Guía didáctica para el aprendizaje del Lenguaje de Señas Peruano

- Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., ... & Zheng, X. (2016). TensorFlow: Large-scale machine learning on heterogeneous systems.
- Bradski, G., & Kaehler, A. (2008). Learning OpenCV: Computer vision with the OpenCV library. O'Reilly Media.

10. ANEXOS

10.1. Anexo A: Lenguaje de Señas Peruano

<https://repositorio.minedu.gob.pe/bitstream/handle/20.500.12799/5545/Lengua%20de%20se%C3%b1as%20peruana%20gu%C3%ada%20para%20el%20aprendizaje%20de%20la%20lengua%20de%20se%C3%b1as%20peruana%2c%20vocabulario%20b%C3%a1sico.pdf?sequence=1&isAllowed=y>

10.2. Anexo B: Cronograma del Proyecto

(Herramienta de seguimiento: Trello Board URL: <https://trello.com/b/baPa9m4T/inteligencia-artificial>)

10.3. Anexo C: Video corto.

- https://youtu.be/Mds1Tk_MmLc (video de explicacion y demostracion del codigo de lenguaje de señas de letras)
- <https://youtu.be/PjH9EmpFz98> (video explicativo acerca de los gestos mediante reconocimiento de imágenes)
- <https://youtu.be/eQveLFwGc2s> (EXPLICACION DETALLADA DE FUNCIONAMIENTO)
- <https://youtu.be/PjH9EmpFz98> (funcionamiento)

10.4. Anexo D: Dataset de Imágenes

(Datos disponibles bajo solicitud)

10.5. Anexo E:Codigo en GitHub

<https://github.com/yeffererson12355/inteligencia-artificial/tree/main/SE%C3%91AS>