

Reconocimiento del Lenguaje de Señas Peruano Mediante Visión Artificial

Yefferson Miranda Josec
Pablo Sebastián Barriga Nina
Samuel Antony Zapana Ccari

13 de junio de 2025

1. Introducción

La comunicación es un pilar fundamental de la interacción humana y un derecho inalienable. Sin embargo, para la comunidad sorda y con discapacidad auditiva, existen barreras significativas al interactuar con personas no familiarizadas con el lenguaje de señas (IJIRT, 2024; Pereira Silva, 2025). En este contexto, la traducción automática de lenguaje de señas mediante visión artificial emerge como una solución tecnológica prometedora para derribar dichas barreras y fomentar una mayor inclusión social (IJIRT, 2024; Pereira Silva, 2025).

El lenguaje de señas no es una simple mímica ni una representación visual de una lengua oral; se trata de una lengua natural completa, con su propia gramática compleja, creativa y productiva (wikipediaLS; University, 2025). Contrario a la creencia popular, no existe una lengua de señas universal; estas lenguas difieren entre sí tanto en léxico como en gramática, de manera análoga a las lenguas orales (wikipediaLS). Esta diversidad lingüística, junto con la naturaleza visual-gestual y la ausencia de una forma escrita estandarizada, constituye la raíz de muchos de los desafíos técnicos en la traducción automática. Un sistema diseñado para el Lenguaje de Señas Americano (ASL) no es directamente aplicable al Lenguaje de Señas Colombiano (LSC) sin un proceso de adaptación o reentrenamiento significativo, lo que multiplica los esfuerzos de desarrollo y subraya la necesidad de una comprensión profunda de sus estructuras lingüísticas. Además, estudios de neuroimagen indican que los lenguajes de señas se procesan en las mismas áreas cerebrales que el lenguaje hablado en personas oyentes, reforzando su estatus como lenguas naturales (University, 2025).

El objetivo primordial de la traducción automática de lenguaje de señas es proporcionar a las personas sordas acceso a un vasto mundo de información y servicios en línea, mejorando su vida cotidiana y promoviendo su participación plena en la sociedad (Review, 2025). Esta tecnología busca superar las limitaciones de la dependencia de intérpretes humanos —cobertura, duración,

confidencialidad y disponibilidad— (González Ramírez, 2020). Al permitir la interacción en tiempo real entre usuarios de lenguaje de señas y no signantes, las aplicaciones potenciales se extienden a campos críticos como la educación, la atención médica y los entornos laborales y sociales (Santos, 2025).

El campo de la traducción automática de lenguaje de señas ha experimentado una notable evolución. Los primeros intentos, que datan de 1977, se limitaban a emparejar letras del teclado con el alfabeto manual ASL simulado en una mano robótica (wikiMachineTranslation). Posteriormente surgieron sistemas basados en guantes sensorizados —por ejemplo, el CyberGlove— que rastreaban los movimientos de las manos para su análisis y traducción (IJRMPS, 2023). Aunque estos enfoques ofrecían cierta precisión, su complejidad, alto costo y la intrusión de los dispositivos *wearables* representaban barreras significativas para una adopción generalizada (designChallenges2024). Esta limitación impulsó una transición fundamental hacia métodos basados en visión artificial. El uso de cámaras estándar, como las webcams, ofrece un entorno de interacción más natural y otorga mayor libertad al signante al eliminar la necesidad de dispositivos voluminosos (IJRMPS, 2023). No obstante, esta tendencia exige el desarrollo de modelos más robustos capaces de superar los desafíos inherentes a la captura visual en entornos reales, como las variaciones de iluminación, los fondos complejos y los cambios en el punto de vista del signante (IJIRT, 2024). Los avances en inteligencia artificial —en particular, el aprendizaje profundo (Deep Learning)— han sido catalizadores clave en esta evolución, permitiendo el procesamiento de datos visuales complejos y el reconocimiento de patrones intrincados en los gestos de señas (IJIRT, 2024).

2. Problemática

2.1. Barrera comunicativa

La comunidad sorda peruana enfrenta una exclusión lingüística sistémica. Menos del 0.1 % de la población oyente domina la Lengua de Señas Peruana (LSP), según el Instituto Nacional de Estadística e Informática (INEI) (de Estadística e Informática, 2022). Esta brecha genera aislamiento comunicativo en entornos educativos, servicios de salud, trámites legales e interacciones laborales cotidianas.

2.2. Falta de intérpretes

La escasez de intérpretes certificados es crítica —en especial en zonas rurales y periurbanas. Mientras Lima concentra el 70 % de los profesionales acreditados, regiones como Amazonas, Huancavelica o Cajamarca carecen casi por completo de servicios especializados (de Estadística e Informática, 2022). La mayoría de docentes fuera de la capital desconoce estrategias pedagógicas bilingües LSP—español (del Pueblo, 2022).

2.3. Exclusión multidimensional: educación, salud y ciudadanía

2.3.1. Educativa

El 78 % de estudiantes sordos matriculados en escuelas regulares reciben clases sin adaptaciones en LSP y con materiales didácticos visuales prácticamente inexistentes (del Pueblo, 2022). Esta carencia afecta el rendimiento académico y la permanencia escolar.

2.3.2. Sanitaria

El 62 % de personas sordas declara no comprender diagnósticos médicos (de Salud, 2017). Ante la falta de intérpretes, el personal sanitario recurre a familiares no capacitados como “puentes comunicativos”, vulnerando la confidencialidad y la calidad de la atención.

2.3.3. Ciudadana

Trámites bancarios, denuncias policiales o procesos judiciales se realizan sin garantías lingüísticas. Solo el 12 % de comisarías del país dispone de intérpretes, exponiendo a personas sordas a riesgos de injusticia procesal (del Pueblo, 2022).

Esta problemática evidencia la urgencia de soluciones tecnológicas —como los sistemas de traducción de lenguaje de señas por visión artificial— que puedan reducir las barreras de comunicación y promover la plena inclusión social.

3. Marco Teórico

3.1. Principios fundamentales

3.1.1. Adquisición y preprocesamiento de datos visuales

La fase inicial y crítica de cualquier sistema de traducción de lenguaje de señas basado en visión artificial es la adquisición de datos visuales. Esto implica la captura de imágenes o secuencias de video de gestos, comúnmente con cámaras estándar o webcams integradas (IJIRT, 2024). Las secuencias se descomponen en fotogramas individuales (p. ej., uno cada 0.0033 s) para su procesamiento subsecuente (García, 2020). Una vez adquiridos, los datos requieren un preprocesamiento exhaustivo para optimizar el rendimiento del modelo y mejorar su robustez ante las variaciones del mundo real (Santos, 2025). Entre las técnicas más empleadas se incluyen:

- **Filtrado:** conversión a blanco y negro para eliminar interferencias cromáticas y resaltar patrones esenciales (García, 2020).
- **Redimensionamiento:** estandarizar resoluciones (p. ej., de 640x380 a 320x240 px, o a 640x640 px) para uniformar el dataset y mejorar la eficiencia computacional (Santos, 2025).

- **Ajuste de contraste y escala de grises:** refuerza la claridad visual y la tolerancia a variaciones de iluminación (Santos, 2025).
- **Auto-orientación:** corrige la alineación independientemente de la orientación original (Santos, 2025).
- **Eliminación de ruido y segmentación:** aislamiento de la región de interés (ROI), suprimiendo fondos complejos o sombras (Gupta, 2023).
- **Normalización:** escalar los valores de píxel (0–1) para estandarizar la entrada de los modelos (García, 2020).
- **Vectorización:** transformar las imágenes (p. ej., 320x240 px) en vectores de 76,800 elementos aptos para algoritmos de aprendizaje (García, 2020).

3.1.2. Técnicas de visión por computadora para el reconocimiento de gestos

La visión por computadora permite a las máquinas procesar, analizar y comprender la gestualidad de las señas (Pereira amp; Silva, 2025). Entre las técnicas clave destacan:

- **Detección y seguimiento de puntos clave:** herramientas como MediaPipe detectan 21 puntos por mano y permiten un seguimiento robusto en tiempo real (Edge, 2025a), mientras que OpenPose provee estimación esquelética detallada (Ko, 2016). El uso de representaciones esqueléticas reduce la sensibilidad a iluminación, fondo y color de piel, mejora la eficiencia computacional y preserva la privacidad al excluir rasgos faciales (Santos, 2025).
- **Extracción de características manuales y no manuales:** las señas combinan parámetros como configuración de la mano, orientación de la palma, lugar de articulación, movimiento y plano de ejecución (Wikipedia contributors, 2025). Además, expresiones faciales, movimiento corporal y dirección de la mirada aportan información semántica esencial (IJIRT, 2024). Por ello, los sistemas deben analizar simultáneamente articuladores manuales y no manuales (García, 2020).

3.1.3. Modelos de aprendizaje profundo

El Deep Learning ha revolucionado la visión por computadora y el PLN, superando a las técnicas tradicionales en reconocimiento de señas (Sharma, 2025). Los enfoques más relevantes son:

- **CNNs:** excelentes para extraer características espaciales; modelos como YOLOv11 y YOLOv8n combinan precisión (98.2 mAP@0.5 para alfabeto ASL) y velocidad en tiempo real (Santos, 2025; Ultralytics, 2025).

- **RNNs / LSTMs:** capturan dependencias temporales en secuencias de video y mantienen memoria de movimientos previos, alcanzando WER de 7.74 para 40 oraciones ASL (Pereira Silva, 2025).
- **Transformers:** gracias a la auto-atención paralela, son punteros en reconocimiento continuo (CSLR), con 96.3 % de precisión y WER de 4.22 en 40 oraciones ASL (Sharma, 2025).
- **Modelos híbridos/multimodales:** combinan CNNs (espacial) con LSTMs o Transformers (temporal) e integran datos de profundidad, IMU o EMG, mejorando la comprensión global de la señal (Sharma, 2025).

3.2. Arquitecturas de sistemas

3.2.1. Señas aisladas vs. continuas

El Reconocimiento de Señas Aisladas (ISLR) trata cada gesto como unidad independiente (Sharma, 2025), mientras que el Reconocimiento Continuo (CSLR) identifica secuencias sin conocer sus límites, enfrentando co-articulación y señal no manual mezclada (Fernández-Mora, 2024). Los principales desafíos en CSLR son el seguimiento preciso, la segmentación y la gestión de vocabularios extensos en tiempo real (Fernández-Mora, 2024).

3.2.2. Enfoques en cascada

Los sistemas tradicionales dividen la tubería en SLR → Gloss2Text (Slator, 2025). Permiten optimizar cada módulo y son útiles en idiomas con pocos recursos, pero sufren propagación de errores y mayor latencia (Wei, 2023).

3.2.3. Enfoques de extremo a extremo

Mapean directamente video → texto, reduciendo latencia y complejidad (Wei, 2023). Su principal limitación es la escasez de grandes corpus video-texto; técnicas como back-translation, pre-entrenamiento y Cross-Modality Data Augmentation (XmDA) mitigan esta carencia (Wei, 2023).

3.2.4. Generación de lenguaje de señas (SLP)

Para comunicación bidireccional, la traducción texto → señas es igual de crucial. Modelos como SignNet y proyectos colaborativos tipo SignGPT exploran la síntesis de señas a partir de texto, generando datos sintéticos que alivian la escasez de corpus (Chan, 2020; of Surrey, 2025). La co-creación con la comunidad sorda garantiza precisión lingüística y aceptación cultural (of Surrey, 2025).

4. Avances Recientes y Estado del Arte (2023–2025)

El campo de la traducción de lenguaje de señas por visión artificial ha experimentado una aceleración significativa en los últimos años, impulsada por

innovaciones en modelos de aprendizaje profundo, mejoras en la precisión y eficiencia y estrategias avanzadas de aumento y generación de datos.

4.1. Innovaciones en modelos de Deep Learning

La convergencia de modelos avanzados de visión por computadora con modelos temporales sofisticados y la incipiente integración de IA generativa y Grandes Modelos de Lenguaje (LLMs) representa una rápida progresión en el campo, motivada por la necesidad de una comprensión lingüística más matizada y una mayor eficiencia de datos.

- **YOLOv11 y MediaPipe.** La combinación de YOLOv11 para el reconocimiento rápido de gestos y MediaPipe para la detección precisa de puntos clave (21 por mano) ha mostrado una precisión de 98.2 mAP@0.5 para el alfabeto ASL, con una notable eficiencia en tiempo real (Edge, 2025a; Ultralytics, 2025). Estos sistemas son robustos incluso bajo condiciones de iluminación y fondos variables (Ultralytics, 2025).
- **Modelos Transformer.** Se han consolidado como la arquitectura de referencia para el Reconocimiento Continuo de Lenguaje de Señas (CSLR), superando a CNNs y RNNs en tareas complejas. Su mecanismo de auto-atención captura dependencias temporales intrincadas (Sharma, 2025). Modelos basados en BERT y Transformers específicos han reducido significativamente la tasa de error de palabras (WER) en CSLR (Edge, 2025a; Sharma, 2025).
- **Grandes Modelos de Lenguaje (LLMs).** Crece el interés por integrar LLMs generativos en tareas de SLR para producir descripciones textuales detalladas o interpretar características espaciales-temporales. Proyectos como Drishti y SignGPT exploran activamente esta vía (of Surrey, 2025). Aunque prometedores, los LLMs generales enfrentan desafíos de imprecisión y “alucinaciones”, lo que exige investigación adicional para garantizar fiabilidad (Santos, 2025).
- **Modelos ligeros.** El desarrollo de redes compactas y eficientes (p. ej., MobileNet) es crucial para la ejecución en dispositivos con recursos limitados (teléfonos o *edge devices*), favoreciendo la portabilidad y accesibilidad (Sharma, 2025).

4.2. Mejoras en precisión y eficiencia en tiempo real

Los sistemas actuales exhiben precisión sobresaliente, especialmente en reconocimiento de alfabeto y señas aisladas: 99.38 % para fingerspelling ASL con CNNs y 99.99 % para el alfabeto BdSL con ResNet-18 (Sharma, 2025). Para CSLR, los Transformers alcanzan 96.3 % de precisión en el conjunto CSL y 97.07 % en AUTSL (Santos, 2025). La optimización de velocidad de inferencia es

clave para cumplir los requisitos de tiempo real, mientras que la robustez frente a variaciones ambientales y entre signantes continúa mejorando (Ultralytics, 2025).

4.3. Estrategias de aumento y generación de datos sintéticos

La escasez de datos anotados —conjuntos de señas mucho más pequeños que los de lenguaje hablado— sigue siendo un reto fundamental (Sharma, 2025). La falta de una forma escrita estándar obliga a trabajar directamente con video crudo, encareciendo y complejizando la anotación experta.

- **Aumento tradicional:** rotaciones, zoom, traslaciones incrementan la diversidad de muestras (Edge, 2025a).
- **Secuencias esqueléticas sintéticas:** generación de esqueletos articulados para SLT (Santos, 2025).
- **Sign stitching:** combinación de señas reales para formar nuevas secuencias (Kim, 2025).
- **Modelos generativos fotorrealistas:** SignGAN y SignSplat producen señas de alta fidelidad, mejorando el rendimiento de SLT hasta un 19 % (Kim, 2025).

4.4. Conjuntos de datos públicos clave

Con estos avances —desde arquitecturas mixtas YOLOv11 + MediaPipe hasta Transformers optimizados y generadores de datos sintéticos— el estado del arte (2023–2025) demuestra progresos sustanciales en precisión, eficiencia y accesibilidad, pero también subraya la necesidad continua de conjuntos de datos más amplios y de una colaboración estrecha con la comunidad sorda para garantizar soluciones éticas y culturalmente pertinentes.

5. Antecedentes y Aplicaciones Prácticas

La investigación y el desarrollo en la traducción de lenguaje de señas por visión artificial han trascendido el ámbito académico para generar prototipos funcionales y productos comerciales, lo que demuestra una fuerte demanda social y una tecnología en maduración (IJIRT, 2024). Este progreso marca la transición de la curiosidad académica a soluciones concretas que abordan brechas de accesibilidad en el mundo real.

5.1. Sistemas de comunicación en tiempo real

El objetivo principal de esta tecnología es facilitar la comunicación directa entre usuarios de lenguaje de señas y no-signantes (Santos, 2025). Proyectos como SUMA en Bolivia (for Tomorrow LatAm, 2025) y el sistema desarrollado por

la Florida Atlantic University (FAU) en EE. UU. (Ultralytics, 2025; University, 2025) logran la interpretación en tiempo real, ofreciendo salida en voz audible y texto en pantalla para una audiencia más amplia (Santos, 2025). La integración con webcams estándar y cámaras de dispositivos cotidianos hace cada vez más ubicua esta capacidad (Santos, 2025).

5.2. Herramientas de accesibilidad en educación y salud

- **Educación.** Estos sistemas promueven entornos de aprendizaje inclusivos, permitiendo a estudiantes sordos interactuar fluidamente con docentes y compañeros; ejemplos como SignAll se emplean ya en instituciones educativas (Translate, 2025).
- **Salud.** La interpretación de señas en tiempo real cierra la brecha de comunicación entre pacientes sordos y profesionales médicos, garantizando mejor atención y comprensión mutua (Santos, 2025).

En un sentido amplio, estas tecnologías potencian el acceso a la participación social y oportunidades laborales para la comunidad sorda (IJIRT, 2024).

5.3. Integración en dispositivos móviles y plataformas web

La portabilidad es clave para la adopción: aplicaciones móviles de traducción de señas se desarrollan activamente (Chernysh, 2025). La optimización para *edge devices* con frameworks ligeros como TensorFlow Lite impulsa el despliegue en teléfonos y hardware de bajo consumo (Sharma, 2025). Soluciones como ProDeaf (WebLibras) y SignAll ofrecen interfaces web accesibles a través de múltiples dispositivos (Translate, 2025).

5.4. Proyectos de I+D destacados

- **SUMA (Bolivia):** proyecto estudiantil que usa Python e IA para detección de señas en tiempo real, reduciendo barreras de comunicación (for Tomorrow LatAm, 2025).
- **Sistema FAU (EE. UU.):** integra YOLOv11 y MediaPipe, alcanzando alta precisión y robustez en múltiples entornos (Ultralytics, 2025; University, 2025).
- **Drishti (AUM, EE. UU.):** herramienta impulsada por IA y LLMs que transforma gestos en texto mediante webcam estándar (at Montgomery, 2025).
- **SignAll Technologies:** pionera en traducción bidireccional ASL–inglés con visión por computadora y PLN, orientada a educación y trabajo (Translate, 2025).
- **ProDeaf (Brasil):** software que convierte texto y voz a Libras, con beta para ASL (Translate, 2025).

- **SignGPT (Reino Unido):** proyecto de £8.45 M para un LLM de lenguaje de señas, enfocado en co-creación con la comunidad sorda y generación masiva de datos (of Surrey, 2025).

Estos desarrollos confirman que la traducción de señas por visión artificial ya no es una curiosidad académica sino un campo con aplicaciones tangibles, impulsado por la necesidad de inclusión (IJIRT, 2024).

5.5. Instituciones, empresas y proyectos de código abierto líderes

5.5.1. Panorama de la investigación académica

Universidades y centros de prestigio lideran la innovación fundamental:

- Florida Atlantic University (FAU) (University, 2025).
- Auburn University at Montgomery (AUM) (at Montgomery, 2025).
- Consorcio University of Surrey – Oxford – UCL (proyecto SignGPT) (of Surrey, 2025).
- Gallaudet University y Brown University, participantes en la Coalition for Sign Language Equity in Technology (CoSET) (Force, 2025).

La colaboración interdisciplinaria con lingüistas sordos asegura precisión cultural y lingüística (of Surrey, 2025).

5.5.2. Empresas desarrolladoras de tecnología SLR/SLT

- SignAll Technologies (ASL bidireccional en tiempo real) (Translate, 2025).
- Signapse (BSL/ASL con signantes fotorrealistas) (Translate, 2025).
- VSLLabs, Sign-Speak, CirrusTranslate, EQ4All, Sign Time GmbH y otras: ofrecen traducción con IA, avatares animados y servicios 24/7 (Translate, 2025; Wire, 2025).

5.5.3. Iniciativas de código abierto y colaboración comunitaria

- MediaPipe, TensorFlow/TensorFlow Lite y OpenCV: pilares abiertos para seguimiento de manos y redes neuronales (Edge, 2025a, 2025c).
- WLASL y OpenASL: *datasets* masivos de ASL esenciales para entrenamiento (Patil, 2025).
- Repositorios en GitHub con arquitecturas CNN+LSTM, 3D CNN, GCN y Transformers demuestran la vitalidad comunitaria (GitHub, 2025).
- CoSET: impulsa estándares de equidad y aboga por la inclusión de todas las lenguas de señas (Force, 2025).

- GoSign.AI: recolección global de datos de lenguas de señas, mitigando la escasez de corpus (Force, 2025).
- SignGPT: generará el mayor *dataset* de señas y herramientas abiertas de anotación con co-creación de la comunidad (of Surrey, 2025).

La sinergia entre academia, industria y comunidad —facilitada por código abierto— acelera la innovación y aborda la naturaleza de “bajos recursos” de los lenguajes de señas (Sharma, 2025).

6. Descripción del Problema o Necesidad

- **Relevancia:** La comunicación es un pilar fundamental de la interacción humana y un derecho inalienable. Para la comunidad sorda y con discapacidad auditiva, existen barreras significativas al interactuar con personas no familiarizadas con el lenguaje de señas (IJIRT, 2024; Pereira & Silva, 2025). En este contexto, la traducción automática de lenguaje de señas mediante visión artificial emerge como una solución tecnológica prometedora para derribar dichas barreras y fomentar una mayor inclusión social (IJIRT, 2024; Pereira & Silva, 2025).
- **Problema central:** La comunidad sorda peruana enfrenta una exclusión lingüística sistémica. Menos del 0.1 % de la población oyente domina la Lengua de Señas Peruana (LSP), según el Instituto Nacional de Estadística e Informática (INEI) (de Estadística e Informática, 2022). Esta brecha genera aislamiento comunicativo en entornos educativos, servicios de salud, trámites legales e interacciones laborales cotidianas.
- **Necesidad:** El objetivo primordial de la traducción automática de lenguaje de señas es proporcionar a las personas sordas acceso a un vasto mundo de información y servicios en línea, mejorando su vida cotidiana y promoviendo su participación plena en la sociedad (Review, 2025). Esta tecnología busca superar las limitaciones de la dependencia de intérpretes humanos —cobertura, duración, confidencialidad y disponibilidad— (González & Ramírez, 2020). Al permitir la interacción en tiempo real entre usuarios de lenguaje de señas y no signantes, las aplicaciones potenciales se extienden a campos críticos como la educación, la atención médica y los entornos laborales y sociales (Santos, 2025).
- **Vinculación tecnológica:** El campo de la traducción automática de lenguaje de señas ha experimentado una notable evolución, pasando de guantes sensorizados a métodos basados en visión artificial con cámaras estándar (IJIRMPs, 2023). Los avances en inteligencia artificial —en particular, el aprendizaje profundo (Deep Learning)— han sido catalizadores clave, permitiendo el procesamiento de datos visuales complejos y el reconocimiento

de patrones intrincados en los gestos de señas (IJIRT, 2024). Esto evidencia la urgencia de soluciones tecnológicas que puedan reducir las barreras de comunicación y promover la plena inclusión social.

7. Objetivos

7.1. Objetivo General

Proporcionar a las personas sordas acceso a un vasto mundo de información y servicios en línea mediante la traducción automática de lenguaje de señas a través de visión artificial, mejorando su vida cotidiana y promoviendo su participación plena en la sociedad peruana.

7.2. Objetivo Específico

1. Diseñar e implementar un módulo de adquisición y preprocesamiento de datos visuales de Lenguaje de Señas Peruano (LSP) que integre la detección y seguimiento de puntos clave manuales y la extracción de características no manuales (faciales, corporales) utilizando cámaras estándar.
2. Desarrollar y entrenar un sistema de reconocimiento de LSP basado en arquitecturas de aprendizaje profundo (como CNNs, RNNs/LSTMs y/o Transformers), optimizando su precisión y eficiencia tanto para señas aisladas como para el desafío de reconocimiento continuo (CSLR).
3. Investigar y aplicar métodos avanzados de aumento y generación de datos sintéticos (e.g., secuencias esqueleticas, *sign stitching*, modelos generativos fotorrealistas como SignGAN) para mitigar la escasez de corpus anotados específicos para el LSP.
4. Evaluar el rendimiento del sistema desarrollado bajo diversas condiciones ambientales y de signantes, así como su viabilidad para despliegue en dispositivos de borde o plataformas accesibles.

8. Alcances y Limitaciones

8.1. Alcances

- El proyecto se centrará en el **reconocimiento de señas del Lenguaje de Señas Peruano (LSP)**, lo que implica el análisis de configuraciones de la mano, orientación de la palma, lugar de articulación, movimiento y plano de ejecución, así como expresiones faciales, movimiento corporal y dirección de la mirada (Wikipedia contributors, 2025; IJIRT, 2024).
- El sistema estará diseñado para funcionar con **cámaras estándar o webcams** (IJIRT, 2024), buscando un entorno de interacción natural que elimine la necesidad de dispositivos *wearables* voluminosos (IJIRMPs, 2023).

- Se emplearán **modelos de aprendizaje profundo de última generación** como CNNs (YOLOv11, YOLOv8n), RNNs/LSTMs y Transformers, así como herramientas como MediaPipe y OpenPose para la detección y seguimiento de puntos clave en tiempo real (Edge, 2025a; Ultralytics, 2025; Sharma, 2025; Ko, 2016).
- El proyecto abordará el **Reconocimiento de Señas Aisladas (ISLR)** y, en la medida de lo posible, explorará soluciones para el **Reconocimiento Continuo (CSLR)**, abordando la complejidad de gestos dinámicos y co-articulación (Fernández-Mora, 2024).
- Se incluirán técnicas de **preprocesamiento exhaustivo de datos visuales** para optimizar el rendimiento del modelo y mejorar su robustez, tales como filtrado, redimensionamiento, ajuste de contraste, eliminación de ruido, segmentación y normalización (García, 2020; Santos, 2025; Gupta, 2023).
- Se investigarán y aplicarán **estrategias de aumento y síntesis de datos** para compensar la escasez de corpus anotados, incluyendo rotaciones, zoom, traslaciones, secuencias esqueléticas sintéticas, *sign stitching* y modelos generativos fotorrealistas (Sharma, 2025; Kim, 2025).

8.2. Limitaciones

- **Escasez y diversidad de datos:** El principal obstáculo es la limitación de corpus anotados específicos para el Lenguaje de Señas Peruano, que son escasos y costosos de crear. La ausencia de una forma escrita estandarizada agrava la situación al requerir transcripción visual especializada (Sharma, 2025).
- **Variabilidad lingüística y cultural:** Las lenguas de señas no son universales. Un sistema entrenado para ASL no generaliza a LSP sin un re-entrenamiento profundo y una adaptación significativa, lo que multiplica los esfuerzos de desarrollo (Wikipedia contributors, 2025).
- **Complejidad de gestos dinámicos y co-articulación:** El CSLR presenta desafíos inherentes como la co-articulación, la ausencia de límites claros entre señas y la mezcla de señales no manuales, lo que complica la segmentación y el reconocimiento preciso (Fernández-Mora, 2024).
- **Condiciones ambientales y robustez:** A pesar de los avances en modelos como YOLOv11 con MediaPipe, factores como las variaciones significativas en la iluminación, los fondos complejos y los cambios en el punto de vista del signante pueden seguir afectando la precisión del sistema en entornos reales (IJIRT, 2024; Ultralytics, 2025).
- **Privacidad y ética:** La necesidad de capturar rasgos faciales para interpretar información no manual esencial en el lenguaje de señas plantea

desafíos de anonimización de videos y privacidad. Un desarrollo ético requiere la co-creación y validación constante con la comunidad sorda (of Surrey, 2025).

- **Generación de lenguaje de señas (SLP):** Aunque se reconoce su importancia para la comunicación bidireccional, el alcance primario de este proyecto es el reconocimiento (video a texto/interpretación). La síntesis robusta de señas a partir de texto o habla (SLP) podría ser un alcance futuro o un módulo con desarrollo limitado en esta fase (Chan, 2020; of Surrey, 2025).

9. Metodología

9.1. Procedimientos

La metodología para el desarrollo del sistema de reconocimiento de Lenguaje de Señas Peruano mediante visión artificial seguirá un enfoque iterativo, combinando la adquisición de datos, el preprocesamiento, el desarrollo de modelos y la evaluación constante, incorporando las últimas innovaciones del campo.

Paso 1. Adquisición y Preprocesamiento de Datos Visuales:

- **Captura:** Se capturarán imágenes o secuencias de video de gestos de LSP utilizando cámaras estándar o webcams (IJIRT, 2024). Las secuencias se descompondrán en fotogramas individuales (p. ej., uno cada 0,0033 s) para procesamiento (García, 2020).
- **Preprocesamiento:** Se aplicarán técnicas de preprocesamiento para optimizar el rendimiento y la robustez: filtrado (conversión a blanco y negro), redimensionamiento (p. ej., de 640×380 a 320×240 px, o a 640×640 px) para uniformar el dataset y mejorar la eficiencia computacional (Santos, 2025). Ajuste de contraste y escala de grises para reforzar la claridad visual y la tolerancia a variaciones de iluminación (Santos, 2025). Auto-orientación para corregir la alineación (Santos, 2025). Eliminación de ruido y segmentación (aislamiento de la ROI), suprimiendo fondos complejos o sombras (Gupta, 2023). Normalización de los valores de píxel (0–1) para estandarizar la entrada de los modelos (García, 2020). Vectorización de las imágenes (p. ej., 320×240 px) en vectores de 76,800 elementos aptos para algoritmos de aprendizaje (García, 2020).

Paso 2. Detección y Seguimiento de Puntos Clave y Extracción de Características:

- **Detección de Puntos Clave:** Se utilizarán herramientas como **MediaPipe** para detectar 21 puntos por mano y **OpenPose** para

estimación esquelética detallada, permitiendo un seguimiento robusto en tiempo real. Estas representaciones esqueléticas reducen la sensibilidad a iluminación, fondo y color de piel, mejorando la eficiencia computacional y preservando la privacidad (Edge, 2025a; Ko, 2016; Santos, 2025).

- *Extracción de Características*: Se analizarán parámetros manuales de las señas (configuración de la mano, orientación de la palma, lugar de articulación, movimiento y plano de ejecución). Simultáneamente, se extraerán características no manuales: expresiones faciales, movimiento corporal y dirección de la mirada, que aportan información semántica esencial (García, 2020; IJIRT, 2024; Wikipedia contributors, 2025).

Paso 3. Selección y Entrenamiento de Modelos de Aprendizaje Profundo:

- *CNNs*: Se emplearán **YOLOv11** y **YOLOv8n** para extraer características espaciales y el reconocimiento rápido de gestos, dada su alta precisión (98,2 % mAP@0,5 para alfabeto ASL) y velocidad en tiempo real (Santos, 2025; Ultralytics, 2025).
- *RNNs / LSTMs*: Se utilizarán para capturar dependencias temporales en secuencias de video, manteniendo memoria de movimientos previos (Pereira & Silva, 2025).
- *Transformers*: Se priorizarán para el Reconocimiento Continuo de Lenguaje de Señas (CSLR) debido a su mecanismo de atención paralela, que los hace punteros en reconocimiento continuo con altas precisiones (Sharma, 2025). Se explorará la integración con LLMs para descripciones textuales detalladas (of Surrey, 2025).
- *Modelos Híbridos/Multimodales*: Se investigará la combinación de CNNs (espacial) con LSTMs o Transformers (temporal) para una comprensión global de la seña, integrando potencialmente datos de profundidad u otros sensores (Sharma, 2025).
- *Optimización para Edge Devices*: Se considerarán modelos ligeros como **MobileNet** para su despliegue en dispositivos de borde (Sharma, 2025).

Paso 4. Aumento y Generación de Datos Sintéticos:

- Para combatir el déficit de datos anotados en LSP, se aplicará aumento tradicional (rotaciones, zoom, traslaciones) (Edge, 2025a).
- Se generarán secuencias esqueléticas sintéticas y se utilizará *sign stitching* para crear nuevas secuencias de señas (Kim, 2025; Santos, 2025).

- Se explorará el uso de modelos generativos fotorrealistas como **SignGAN** y **SignSplat** para producir datos sintéticos de alta fidelidad, que pueden mejorar la precisión hasta un 19 % (Kim, 2025; Sharma, 2025).

Paso 5. Evaluación y Optimización del Sistema:

- Se medirá la precisión del modelo (mAP, WER) y la eficiencia en tiempo real.
- Se optimizará la velocidad de inferencia, posiblemente utilizando **TensorFlow Lite** para despliegue en dispositivos móviles (Sharma, 2025; Edge, 2025b).
- Se ajustarán parámetros y se reentrenará el modelo para mejorar la robustez frente a variaciones ambientales y entre signantes (Ultralytics, 2025).

Paso 6. Integración y Despliegue (Demostrador/Prototipo):

- Se considerará la integración en una aplicación móvil (utilizando Android Studio con Jetpack Compose, ML Kit, CameraX) o una plataforma web para demostrar la accesibilidad (Developers, 2025; Droidcon, 2025).

9.2. Modelos Computacionales

9.3. Herramientas Tecnológicas

▪ Bibliotecas de Programación y Frameworks:

- **MediaPipe:** Esencial para la detección de gestos y el seguimiento de puntos clave (Edge, 2025a).
- **TensorFlow / TensorFlow Lite:** Frameworks de *Deep Learning* para el desarrollo, entrenamiento y despliegue de modelos, especialmente en *edge devices* (Edge, 2025b).
- **OpenCV:** Para tareas generales de procesamiento de imágenes y video (GitHub, 2025).
- **PyTorch / Keras:** Otros frameworks de *Deep Learning* a considerar para la implementación de modelos.
- **ML Kit de Google:** Para la integración de funcionalidades de ML en aplicaciones móviles (Droidcon, 2025).

▪ Hardware:

- **Cámaras estándar / webcams de alta resolución:** Para la adquisición de datos visuales del signante.

Cuadro 1: Algoritmos y Arquitecturas de Modelos Clave para Implementación

Modelo/Arquitectura	Función Principal en el Proyecto
YOLOv11 / YOLOv8n	Detección de objetos y reconocimiento rápido de tos en tiempo real; extracción de característi- cias espaciales de manos y cuerpo.
MediaPipe	Detección y seguimiento de 21 puntos clave mano, estimación de pose facial y corporal para tos esqueléticos.
OpenPose	Complemento para estimación esquelética detallada del cuerpo completo, mejorando la robustez en el seguimiento.
Redes Neuronales Recurrentes (RNNs) / LSTMs	Procesamiento de secuencias temporales de datos señas, capturando la dinámica y el contexto del movimiento.
Transformers	Arquitectura avanzada para Reconocimiento Co- ncepto de Lenguaje de Señas (CSLR) y modelado dependencias a largo plazo en secuencias de video.
MobileNet	Arquitectura de red neuronal convolucional ligera optimizada para inferencia eficiente en dispositi- vos móviles o de borde.
SignGAN / SignSplat	Modelos generativos adversariales para la síntesis señas fotorrealistas y aumento de conjuntos de datos (investigación/exploración).
Modelos Híbridos	Combinaciones de CNNs con LSTMs o Transformers para explotar tanto características espaciales como temporales de las señas.

- **Unidades de Procesamiento Gráfico (GPUs):** Fundamentales para acelerar el entrenamiento y la inferencia de modelos de *Deep Learning*.
- **Dispositivos móviles (Smartphones):** Plataformas objetivo para el despliegue del prototipo, aprovechando sus cámaras integradas y capacidad de procesamiento (Sharma, 2025).

■ **Entornos de Desarrollo:**

- Lenguaje de programación principal: **Python**.
- IDEs: **Visual Studio Code** o **PyCharm**.
- Para desarrollo móvil: **Android Studio** con **Jetpack Compose** y **CameraX** (Developers, 2025).

■ **Conjuntos de Datos Públicos Clave (para referencia y posible pre-entrenamiento):**

- **WLASL y OpenASL:** Grandes *datasets* de ASL que pueden ser esenciales para entrenamiento y pre-entrenamiento de modelos, dada la escasez de datos específicos de LSP (Patil, 2025).
- **Repositorios en GitHub:** Fuentes de arquitecturas CNN+LSTM, 3D CNN, GCN y Transformers (GitHub, 2025).

10. Recursos

10.1. Recursos Humanos

Cuadro 2: Equipo de trabajo estimado y Roles Clave

Rol	Responsabilidades Clave
Investigador Principal / Líder de Proyecto	Dirección general del proyecto, supervisión de investigación y desarrollo, gestión de recursos.
Ingeniero de Visión por Computadora	Diseño e implementación de los algoritmos de procesamiento de imágenes/video, desarrollo de pipelines de seguimiento. Optimización de la eficiencia.
Ingeniero de Machine Learning / Deep Learning	Selección, desarrollo, entrenamiento y validación de modelos neuronales (CNNs como YOLO, RNNs como LSTM). Optimización y eficiencia del reconocimiento.
Científico de Datos / Especialista en Datos	Gestión y curación de conjuntos de datos, análisis de la generación de datos sintéticos, evaluación de métricas de rendimiento.
Colaborador Lingüista (LSP) / Miembro de la Comunidad Sorda	Aportar conocimiento experto del Lenguaje de Señas Peruano y contexto cultural del sistema. Co-creación de la interfaz de usuario.
Desarrollador de Aplicaciones (Front-end/Móvil)	Diseño e implementación de la interfaz de usuario y la integración del reconocimiento en una aplicación con el usuario final.

10.2. Recursos Financieros

11. Conclusiones y perspectivas futuras

11.1. Resumen de los hallazgos clave

La traducción automática de lenguaje de señas por visión artificial es un ámbito en rápida expansión, motivado por la necesidad de accesibilidad e inclusión de la comunidad sorda a escala global (IJIRT, 2024). El lenguaje de señas, reconocido como lengua natural con gramática y léxico propios, difiere entre regiones, lo que introduce retos intrínsecos para la traducción automática (Wikipedia contributors, 2025).

Cuadro 3: Presupuesto estimado (Valores ilustrativos - a completar según el proyecto real)

Concepto	Costo Unitario Estimado (\$/)
Equipos de Hardware (Cámaras web de alta resolución, PC con GPU)	1,500.00 - 8,000.00
Licencias de Software (si aplica, ej. herramientas de anotación)	0.00 - 500.00
Acceso a plataformas de cómputo en la nube (ej. AWS, GCP, Azure)	200.00 - 1,000.00/mes
Honorarios de personal (si aplica, ej. lingüista, intérpretes para datos)	500.00 - 2,000.00/mes
Materiales y suministros (oficina, prototipado)	100.00 - 300.00
Imprevistos (10 % del total)	-
Total Estimado del Proyecto	

Los avances en Deep Learning han sido decisivos: la evolución desde CNNs (extracción espacial) hasta RNNs/LSTMs (modelado temporal) y, más recientemente, Transformers y la integración incipiente de Grandes Modelos de Lenguaje (LLMs) ha elevado la precisión y el rendimiento en tiempo real (Santos, 2025; Sharma, 2025). Herramientas como YOLO y MediaPipe se han consolidado para la estimación de pose y el seguimiento de puntos clave, proporcionando características visuales robustas y eficientes (Edge, 2025a; Ultralytics, 2025).

La escasez de datos anotados persiste como el principal obstáculo; sin embargo, el aumento y la generación sintética de datos (p. ej., SignGAN, SignSplat) ofrecen soluciones prometedoras (Kim, 2025). Coexisten arquitecturas en cascada y de extremo a extremo, cada una con compromisos entre precisión, latencia y complejidad (Slator, 2025; Wei, 2023). La expansión a lenguas de bajos recursos, como el Quechua, añade desafíos de datos y morfología, pero abre nuevas líneas de investigación (Oncevay, 2024, 2025).

El ecosistema se vuelve cada vez más colaborativo entre academia, industria y comunidad sorda, con fuerte énfasis en la co-creación y la ética (Force, 2025; of Surrey, 2025). Implementaciones móviles basadas en Jetpack Compose, ML Kit, CameraX y TensorFlow Lite confirman la viabilidad de llevar la tecnología al usuario final de forma eficiente y accesible (Developers, 2025; Droidcon, 2025; Edge, 2025b).

11.2. Direcciones de investigación futuras

- **Señas continuas y co-articulación.** Avanzar hacia la interpretación fluida de oraciones completas, modelando con precisión la co-articulación y otros fenómenos dinámicos (Fernández-Mora, 2024).
- **Robustez en entornos diversos.** Aumentar la fiabilidad frente a variaciones de iluminación, fondos complejos y diversidad de signantes (IJIRT, 2024).
- **Modelos ligeros y eficientes.** Optimizar redes para su despliegue en dispositivos móviles y *edge* a fin de mejorar portabilidad y accesibilidad

(Sharma, 2025).

- **Aumento y datos sintéticos avanzados.** Desarrollar técnicas más sofisticadas de generación de datos de alta calidad y diversidad lingüística que mitiguen la escasez de corpus (Kim, 2025).
- **Integración profunda de LLMs.** Explorar cómo los LLMs pueden aportar comprensión semántica y sintáctica, generando descripciones coherentes y contextualizadas (of Surrey, 2025).
- **Sistemas bidireccionales completos (SLP).** Construir traductores texto/habla → señas robustos para una comunicación verdaderamente bidireccional (Chan, 2020; of Surrey, 2025).
- **Estandarización e investigación interlingüística.** Desarrollar soluciones adaptables a múltiples lenguas de señas y fomentar recursos para idiomas de bajos recursos como el Quechua (Force, 2025; Oncevay, 2024).

11.3. Impacto potencial en la inclusión social

La futura interpretación de oraciones completas en dispositivos móviles, co-creada con la comunidad sorda, subraya un imperativo ético: reducir barreras de comunicación potenciará la participación plena en educación, empleo, salud e interacciones diarias (IJIRT, 2024). El éxito reside en tecnologías precisas, accesibles y, sobre todo, validadas por usuarios sordos, garantizando sensibilidad cultural, fidelidad lingüística y empoderamiento auténtico.

12. Referencias

- at Montgomery, A. U. (2025). Warhawk Weekly 5-20: AI Sign Language Tool Research. Consultado el 12 de junio de 2025, desde <https://www.aum.edu/warhawk-weekly-5-20-ai-sign-language-tool-research-softball-season-ends/>
- Chan, D. (2020). A Sign Language Translation System Based on Deep Learning. Consultado el 12 de junio de 2025, desde <https://www.yau-science-awards.org/upload/202007/06/202007061602042782/202007061602042782.pdf>
- Chernysh, R. (2025). Aplicación móvil que traduce el lenguaje de signos. Consultado el 12 de junio de 2025, desde https://rua.ua.es/dspace/bitstream/10045/136547/1/Aplicacion_movil_para_traducir_lenguaje_signos_Chernysh_Roman.pdf
- de Estadística e Informática, I. N. (2022). Perú: Población Sorda y Uso de la Lengua de Señas. Consultado el 13 de junio de 2025, desde <https://www.inei.gob.pe>
- de Salud, M. (2017). Encuesta Nacional sobre Discapacidad (ENSODI) 2017. Consultado el 13 de junio de 2025, desde <https://www.minsa.gob.pe>

- del Pueblo, D. (2022). Informe sobre la situación educativa de las personas sordas en el Perú. Consultado el 13 de junio de 2025, desde <https://www.defensoria.gob.pe>
- Developers, G. (2025). Androidify: Building Powerful AI-Driven Experiences with Jetpack Compose Gemini CameraX. Consultado el 12 de junio de 2025, desde <https://android-developers.googleblog.com/2025/05/androidify-building-ai-driven-experiences-jetpack-compose-gemini-camerax.html>
- Droidcon. (2025). Integrating Google ML Kit for Barcode Scanning in Jetpack Compose Android Apps. Consultado el 12 de junio de 2025, desde <https://www.droidcon.com/2025/01/30/integrating-google-ml-kit-for-barcode-scanning-in->
- Edge, G. A. (2025a). Gesture Recognition Task Guide. Consultado el 12 de junio de 2025, desde https://ai.google.dev/edge/mediapipe/solutions/vision/gesture_recognizer
- Edge, G. A. (2025b). LiteRT for Android. Consultado el 12 de junio de 2025, desde <https://ai.google.dev/edge/litert/android>
- Edge, G. A. (2025c). MediaPipe Framework on Android: Getting Started. Consultado el 12 de junio de 2025, desde https://ai.google.dev/edge/mediapipe/framework/getting_started/android
- Fernández-Mora, P. (2024). A Review of Deep Learning-Based Approaches to Sign Language Processing. Consultado el 12 de junio de 2025, desde <https://www.tandfonline.com/doi/full/10.1080/01691864.2024.2442721>
- Force, S. A. T. (2025). Coalition for Sign Language Equity in Technology (CoSET). Consultado el 12 de junio de 2025, desde <https://safeaitf.org/deafsafeai/>
- for Tomorrow LatAm, S. (2025). Con inteligencia artificial, estudiantes traducen lenguaje de señas en tiempo real. Consultado el 12 de junio de 2025, desde <https://solvefortomorrowlatam.com/es/practica/con-inteligencia-artificial-estudia>
- García, V. (2020). Modelo computacional para reconocimiento de lenguaje de señas. Consultado el 12 de junio de 2025, desde <https://www.redalyc.org/journal/3442/344263272011/>
- GitHub. (2025). sign-language-recognition — Topic Overview. Consultado el 12 de junio de 2025, desde <https://github.com/topics/sign-language-recognition>
- González, J., Ramírez, L. (2020). Modelo computacional para reconocimiento de lenguaje de señas en un contexto colombiano. Consultado el 12 de junio de 2025, desde http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S0123-77992020000200191

- Gupta, K. (2023). Design Challenges in Effective Algorithm Development of Sign Language Recognition System. Consultado el 12 de junio de 2025, desde <https://www.ijeat.org/wp-content/uploads/papers/v12i3/C40300212323.pdf>
- IJIRMPs. (2023). Sign Language Recognition System Using Machine Learning. Consultado el 12 de junio de 2025, desde <https://www.ijirmps.org/papers/2023/6/230387.pdf>
- IJIRT. (2024). Sign Language Detection Using Computer Vision. Consultado el 12 de junio de 2025, desde https://ijirt.org/publishedpaper/IJIRT173884_PAPER.pdf
- Kim, S. (2025). Deep Learning Approaches for Continuous Sign Language Recognition: A Comprehensive Review. Consultado el 12 de junio de 2025, desde https://www.researchgate.net/publication/390220668_Deep_Learning_Approaches_for_Continuous_Sign_Language_Recognition_A_Comprehensive_Review
- Ko, S. (2016). Sign Language Production Pipeline: Machine Translation, Sequence Classification, and Animation. Consultado el 12 de junio de 2025, desde https://www.researchgate.net/figure/Sign-language-production-pipeline-machine-trafig1_301449281
- of Surrey, U. (2025). SignGPT – Project Awarded £8.45 M to Build a Sign Language AI Model for the Deaf Community. Consultado el 12 de junio de 2025, desde <https://www.surrey.ac.uk/news/signgpt-project-awarded-ps845m-build-sign-lang>
- Oncevay, A. (2024). QueEn: A Large Language Model for Quechua–English Translation. Consultado el 12 de junio de 2025, desde <https://arxiv.org/pdf/2412.05184>
- Oncevay, A. (2025). Obtaining Quality (Standard Southern) Quechua Data for NLP Applications. Consultado el 12 de junio de 2025, desde <https://github.com/aoncevay/quechua-nlp>
- Patil, S. (2025). Sign Language Recognition (I3D + Transformers) on WLASL Dataset. Consultado el 12 de junio de 2025, desde <https://github.com/sumedhsp/Sign-Language-Recognition>
- Pereira, R., Silva, M. (2025). Sign Language Translator System Using Computer Vision and LSTM Neural Networks. Consultado el 12 de junio de 2025, desde [enlace sospechoso eliminado]
- Review. (2025). The Sign Language Translator: Bridging the Communication Gap. Consultado el 12 de junio de 2025, desde <https://medium.com/@adnan.raza.ali/the-sign-language-translator-bridging-the-communication-gap-b230238e88>

- Santos, J. (2025). Sign Language Recognition: From Theory to Practice. Consultado el 12 de junio de 2025, desde <https://www.mdpi.com/2076-3417/14/11/4507>
- Sharma, S. (2025). Deep Learning Approaches for Continuous Sign Language Recognition. Consultado el 12 de junio de 2025, desde <https://arxiv.org/pdf/2503.04870>
- Slator, C. (2025). DeepMind Develops AI That Translates Sign Language. Consultado el 12 de junio de 2025, desde <https://slator.com/deepmind-develops-ai-that-translat>
- Translate, V. (2025). Top 10 Sign Language Translator Apps (2025 Update). Consultado el 12 de junio de 2025, desde <https://www.veed.io/learn/sign-language-translator-apps>
- Ultralytics. (2025). YOLOv11 and Computer Vision Innovations in Sign Language Recognition. Consultado el 12 de junio de 2025, desde <https://blog.ultralytics.com/yolov11-computer-vision-innovations-sign-language-recognition/>
- University, C. M. (2025). Sign Language: Facts and History. Consultado el 12 de junio de 2025, desde <https://www.cmu.edu/student-life/diversity/disability-services/awareness/sign-language.html>
- University, F. A. (2025). FAU Developing AI Sign Language Translator to Bridge Communication Gap for Deaf and Hard of Hearing. Consultado el 12 de junio de 2025, desde <https://www.fau.edu/newsdesk/articles/fau-developing-ai-sign-language-translator/>
- Wei, Y. (2023). Bridging the Communication Gap: Sign Language Translation with Deep Learning. Consultado el 12 de junio de 2025, desde https://medium.com/@yu_wei/bridging-the-communication-gap-sign-language-translation-with-dee
- Wikipedia contributors. (2025). Sign language. In Wikipedia, The Free Encyclopedia. Consultado el 12 de junio de 2025, desde https://en.wikipedia.org/wiki/Sign_language
- Wire, B. (2025). Sign-Speak and CirrusTranslate Named to Top Ten List of 2025 AI Startups. Consultado el 12 de junio de 2025, desde <https://www.businesswire.com/news/home/20250109005470/en/Sign-Speak-and-CirrusTranslate-Named-to-T>
- wikiMachineTranslation. (2025). Machine translation - Wikipedia. Consultado el 12 de junio de 2025, desde https://en.wikipedia.org/wiki/Machine_translation#History
- wikipediaLS. (2025). Wikipedia: Lengua de señas. Consultado el 12 de junio de 2025, desde https://es.wikipedia.org/wiki/Lengua_de_se%C3%B1as